

Guía Maestra de Despliegue y Ejecución

Clúster Apache Spark (Ubuntu/Proxmox)

Equipo de Infraestructura y Datos

24 de noviembre de 2025

Índice

1. 1. Introducción	2
2. 2. Prerrequisitos y Configuración de Red	2
2.1. Topología de Red (Obligatorio)	2
2.2. Configuración de Netplan (Paso a Paso)	2
3. 3. Instalación de Software	3
4. 4. Preparación de Datos y Scripts (Solo Master)	3
5. 5. Inicio y Verificación del Clúster	3
5.1. Iniciar Servicios	3
5.2. Verificaciones Técnicas	4
6. 6. Ejecución del Experimento	4
6.1. Fase A: Entrenamiento (script.py)	4
6.2. Fase B: Predicción (prediccion.py)	4
7. 7. Cierre del Clúster	4
A. Anexo: Datos Válidos para Pruebas	6

Recursos del Proyecto

Antes de comenzar, descargue los scripts necesarios (`instalar_spark.sh`, `script.py`, `prediccion.py`) desde el repositorio oficial:

<https://github.com/DesarrolladorSerio/etapa2extraccion/tree/main/app>

1. 1. Introducción

Este documento consolida todas las instrucciones para levantar desde cero un clúster de Apache Spark (1 Master + 2 Workers) y ejecutar los experimentos de regresión lineal. Incluye la configuración de red a nivel de sistema operativo, la instalación automatizada de software y la guía de ejecución de scripts.

2. 2. Prerrequisitos y Configuración de Red

Estado Inicial: 3 Máquinas Virtuales con Ubuntu Server recién instalado (usuario `ubuntu`).

2.1. Topología de Red (Obligatorio)

Para cumplir con el diseño del experimento, es crítico asignar IPs estáticas antes de instalar Spark.

Rol	IP Estática	Hostname Sugerido
MASTER	192.168.1.10	spark-master
WORKER 1	192.168.1.11	spark-worker-1
WORKER 2	192.168.1.12	spark-worker-2

2.2. Configuración de Netplan (Paso a Paso)

Ejecutar en **cada nodo** para fijar la IP:

1. Identificar la interfaz de red:

```
ip a
```

2. Editar configuración:

```
sudo nano /etc/netplan/00-installer-config.yaml
```

3. Pegar el siguiente contenido (Ajustar la IP según la tabla anterior):

```
network:
  version: 2
  ethernets:
    ens18: # Verificar si tu interfaz es ens18 o eth0
      dhcp4: no
      addresses:
        - 192.168.1.10/24 # <--- CAMBIAR SEGN NODO (10, 11 o 12)
```

```
routes:
  - to: default
    via: 192.168.1.1
nameservers:
  addresses: [8.8.8.8, 1.1.1.1]
```

4. Aplicar: `sudo netplan apply`

3. 3. Instalación de Software

Usaremos el script `instalar_spark.sh` (disponible en el repositorio enlazado al inicio) para automatizar la instalación de Java, Python y Spark.

1. Ejecutar en los 3 nodos:

```
chmod +x instalar_spark.sh
sudo ./instalar_spark.sh
```

2. Selección de Roles:

- En la VM **192.168.1.10**: Elegir opción 1) **MASTER**.
- En las VMs **192.168.1.11** y **.12**: Elegir opción 2) **WORKER** e indicar la IP del Master (192.168.1.10).

4. 4. Preparación de Datos y Scripts (Solo Master)

El dataset **pp-complete.csv** y los scripts deben existir únicamente en el Master.

1. Descargar y convertir Dataset:

```
cd /home/ubuntu/
wget "http://prod2.publicdata.landregistry.gov.uk.s3-website-eu-west-1.
amazonaws.com/pp-complete.txt"
mv pp-complete.txt pp-complete.csv
```

Nota: Se renombra a .csv para compatibilidad con el script de entrenamiento.

2. Verificar Scripts: Asegurar que `script.py` y `prediccion.py` estén en `/home/ubuntu/`.

5. 5. Inicio y Verificación del Clúster

5.1. Iniciar Servicios

1. Master:

```
start-master.sh
```

2. Workers:

```
start-worker.sh spark://192.168.1.10:7077
```

5.2. Verificaciones Técnicas

Antes de ejecutar nada, verificar la salud del clúster:

- **Procesos en Master:** `ps aux | grep Master` debe mostrar el proceso activo.
- **Puertos:** `sudo ss -tulpn | grep 7077` (comunicación interna) y 8080 (Web UI).
- **Web UI:** Abrir `http://192.168.1.10:8080`. Debe indicar **Workers: 2 Alive**.
- **Conectividad desde Workers:** Ejecutar en un worker `nc -vz 192.168.1.10 7077`. Debe responder "Connection succeeded".

6. 6. Ejecución del Experimento

6.1. Fase A: Entrenamiento (script.py)

Este proceso limpia los datos, entrena el modelo y lo guarda en `modelos/`.

```
/opt/spark/bin/spark-submit \  
--master spark://192.168.1.10:7077 \  
--deploy-mode client \  
script.py
```

Criterios de Éxito:

- Consola muestra métricas: **RMSE** y R^2 .
- Se crea carpeta: `/home/ubuntu/modelos/`.

6.2. Fase B: Predicción (prediccion.py)

Uso del modelo entrenado para inferencia. Sintaxis: `AÑO MES TIPO NUEVO DURACION CIUDAD`.

Ejemplo 1 (Sunderland):

```
/opt/spark/bin/spark-submit \  
--master spark://192.168.1.10:7077 \  
--deploy-mode client \  
prediccion.py 2026 5 SNF SUNDERLAND
```

Resultado esperado: Precio estimado: £XXX,XXX.

7. 7. Cierre del Clúster

Para detener los servicios ordenadamente:

- En Workers:

```
cd /opt/spark/sbin  
./stop-worker.sh
```

- En Master:

```
cd /opt/spark/sbin  
./stop-master.sh
```

A. Anexo: Datos Válidos para Pruebas

Los siguientes condados/ciudades están presentes en el dataset y son válidos para usar como último parámetro en `prediccion.py`.

- SUNDERLAND
- MILTON KEYNES
- WEST MIDLANDS
- SOUTH YORKSHIRE
- CAMBRIDGESHIRE
- CHESHIRE
- SWANSEA
- NORFOLK
- STAFFORDSHIRE
- GLOUCESTERSHIRE
- GREATER LONDON
- MERSEYSIDE
- ESSEX
- AVON
- WEST SUSSEX
- OXFORDSHIRE
- KENT
- GREATER MANCHESTER
- NORTH YORKSHIRE
- SUFFOLK
- HUMBERSIDE
- WARWICKSHIRE
- WORCESTERSHIRE
- DERBYSHIRE
- LEICESTERSHIRE
- LANCASHIRE